農作業への応用を目指した VLA果実回収システム

再観察の導入と効果の検証

必要に応じた追加観察を、学習済みモデルによるロボット操作へ接続した。机上のリンゴ1個をトレーへ回収するシミュレーションを構築し、再観察あり・なしを同一初期配置で比較した。



図1 提供動画からの場面抜粋。左：固定カメラ、右：手首カメラ。最終比較40試行とは別の動作記録。

構築したもの

RGBによる再観察判断、観察移動、SmolVLAによる把持・搬送・配置を接続した。

検証したこと

既存条件20試行と新規配置20試行を分け、トレー収容と持上げ保持を評価した。

得られた結果

既存の葉あり5条件では収容が2/5から4/5へ増加。新規10配置では両方式4/10で、効果は配置に依存した。

背景と目的

農作業での「見えにくさ」に着目し、観察と操作をつなぐ。

テーマを選んだ経緯

当初は、根の観察や培養液の調製など、栽培管理の自動化を検討していた。その中で、作業対象の状態を十分に観察してから動く仕組みに関心を持ち、果実の遮蔽を題材に再観察と操作の接続へ焦点を絞った。

先行研究から分かったこと

単一視点では果実が隠れる [1]

Hemmingら（2014）は、ピーマンの可視性を複数の撮影位置から調査した。単一視点で生じる遮蔽と、複数視点による見え方の改善を報告している。

撮影する位置・向きが検出に影響する [2]

Kurtser・Edan（2018）は、温室の実画像を用いて果実の検出可能性を分析し、撮影距離やセンサの傾きとの関係を示している。

観察と操作を結ぶ研究の蓄積 [3]

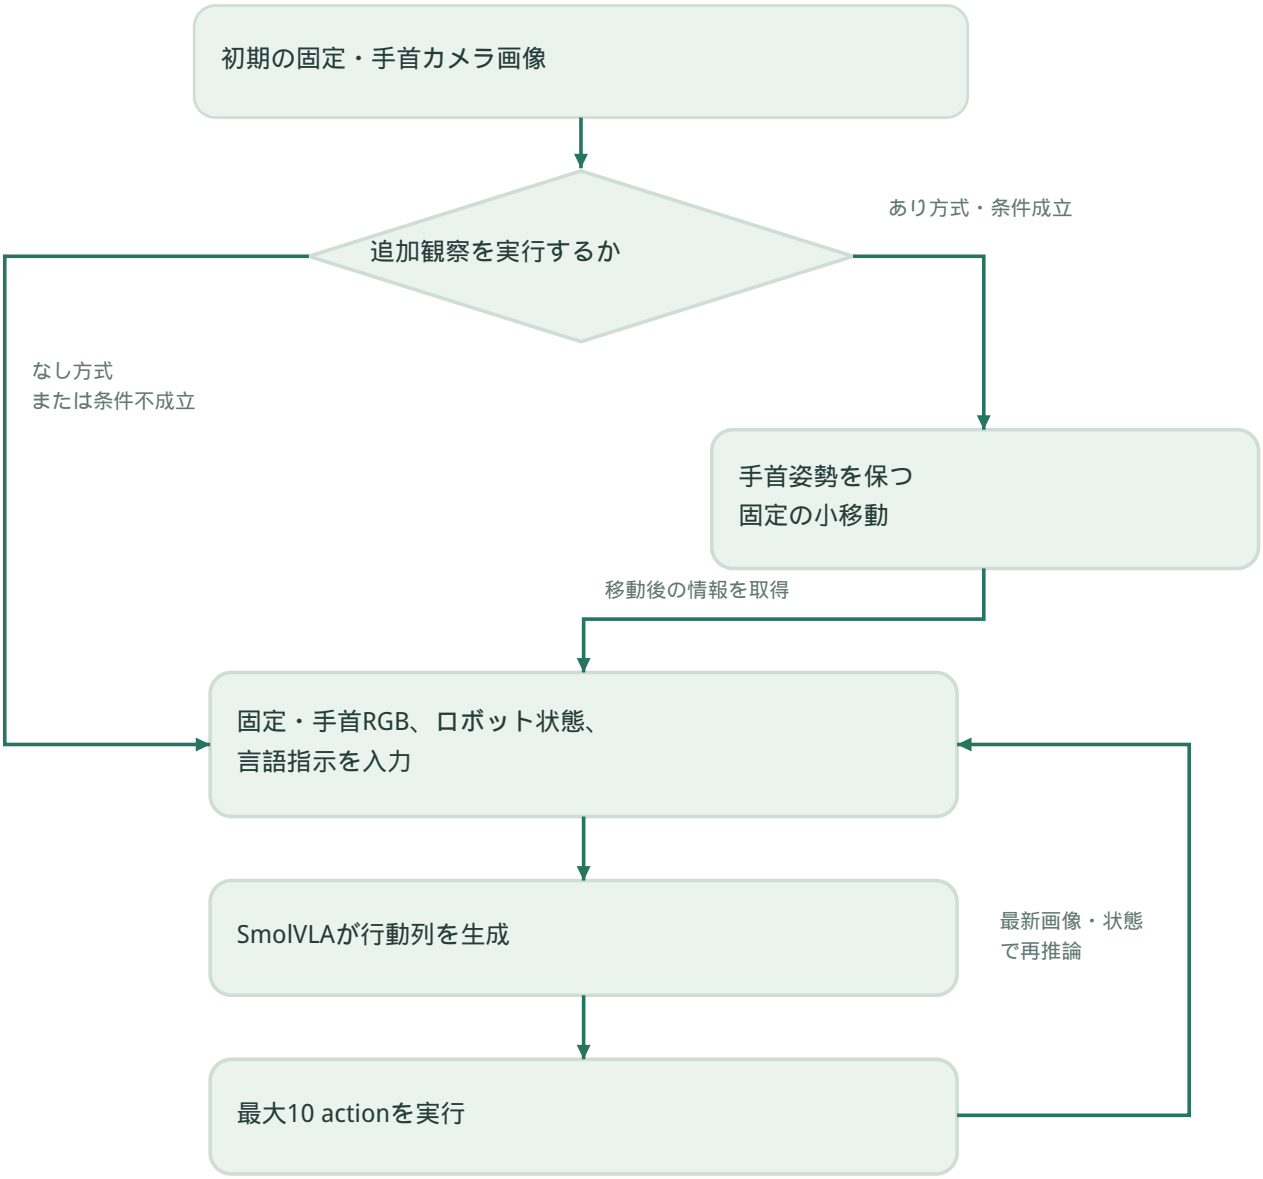
Magalhãesら（2022）のレビューでは、収穫における複数視点や視覚サーボの利用を整理している。本課題では、それらを背景にVLA操作への統合と比較評価へ取り組む。

今回の目的

RGBに基づく追加観察の手順をVLAへ組み込み、果実の回収結果がどのように変わるかを、既存配置と新規配置で評価する。

システム全体

画像による判断、観察移動、VLA操作を一連の処理にする。



追加観察の判断は開始時に一度行う。移動した場合は、行動キューをリセットし、移動後の画像・状態からVLA操作を開始する。再観察なし方式でも、操作中の画像更新と再推論は有効である。

処理	担当
判断・観察移動	色規則と通常のロボット制御
把持・搬送・配置	追加学習したVLAが行動を生成

実装と独自の工夫

公開VLAを基盤に、データ・観察・評価の接続を実装した。

採用モデルと教師データ

ベースにはHuggingFaceVLA/smolvla_libero [4]を使用した。正解位置を使う通常制御で成功教師を生成し、その画像・状態・指示・行動からモデルの一部パラメーターを追加学習した。

段階	データと設定
起点の学習	成功教師1軌道・403フレーム / 2000ステップ
継続学習	成功教師12軌道・5065フレーム / batch 4
採用版	継続学習1250ステップ時点（C1250）

採用した観察・操作の設定

項目	採用設定
必要性判断	2台のRGB画像で、緑画素数250以上、赤 /（赤 + 緑）0.75未満のときに追加観察。
観察動作	世界座標で手先を（+20, +40, -10）mm移動。手首姿勢を保ち、45制御ステップで実行。
VLA入力	固定・手首RGB、8次元の手先・グリッパー状態、言語指示。
VLA出力	7次元の相対action。予測長50のうち最大10 actionを実行して再推論。

正解位置・個数は、教師生成や評価にのみ使用し、再観察判断とVLA入力へ渡さない。教師制御の成功は、VLAの評価成績に含めない。

自分が実装した部分

シーン・タスクの統合 / RGB判断と観察移動 / VLAへの情報引継ぎ / 教師生成と追加学習の処理 / 収容・保持判定 / 条件固定・ログ・比較集計。

比較実験の方法

同じ初期配置をペアにし、追加観察手順の有無を比較した。

評価群	初期配置	試行数
既存条件	遮蔽なし5配置 + 葉あり5配置	2方式で20試行
新規条件	局所の学習・調整・過去評価に未使用の葉あり10配置	2方式で20試行

各ペアで初期状態、seed、モデル重み、指示、物理条件、成功判定を一致させた。総予算は追加観察も含め900制御ステップ（45シミュレーション秒）とし、比較後の追加学習・条件差替えは行っていない。

比較する差

あり方式は条件成立時に45ステップ（2.25シミュレーション秒）の観察移動を行う。なし方式はその移動を省く。両方式ともVLA操作中の画像更新を行う。

二つの成功指標

指標	判定方法
主指標：トレー収容	果実meshの全XY足跡がトレー内、底面が規定の高さ範囲内、開放指令と開口幅の条件を40制御ステップ連続で満たす。
別指標：持上げ・両指保持	開始直前の果実中心より50mm以上の高さと、左右の指の同時接触を40制御ステップ連続で満たす。

40ステップは20Hzで2秒相当の離散判定。収容成功には、搬送後に滑脱してトレーへ入る例も含む。収容成功率と、安定した把持搬送の成功率は区別する。

シーン：同じリンゴ1個・到達可能なトレー。葉は約32×28×2mmの衝突しない板状近似で、初期手首カメラの視線上に配置した。固定カメラからは果実が見える。枝から果実を切り離す収穫は対象に含めない。

比較結果

既存の葉あり条件では収容が増加。新規配置では増加を再現しなかった。

既存条件：各方式5試行ずつ

条件・指標	再観察なし	再観察あり
遮蔽なし：収容	5/5	5/5
葉あり：収容	2/5	4/5
葉あり：持上げ保持	4/5	4/5

新規の葉あり配置：各方式10試行

指標	再観察なし	再観察あり
トレー収容	4/10	4/10
持上げ・両指保持	8/10	5/10

既存の葉あり5条件は、両成功2・ありだけ成功2・なしだけ成功0・両失敗1。新規10配置は、両成功1・ありだけ成功3・なしだけ成功3・両失敗3で、改善と悪化が相殺された。

同じ配置で何が変わったか

既存条件	なし方式からあり方式への変化
leaf02	持上げ保持・収容とも失敗から成功へ
leaf04	持上げ保持は両成功、収容は失敗から成功へ
leaf03	持上げ保持が成功から失敗へ、収容は両失敗

遮蔽なしの持上げ保持は両方式4/5。clear00の2試行は持上げ保持条件に未達でも、搬送後の滑脱を経て収容条件を満たした。厳密な可視率は復元画像の品質確認を通らず欠測とし、数値結果には用いていない。

考察と結論

再観察を操作へ統合できた。今後の焦点は、観察後の操作の安定化。

今回達成したこと

追加観察の判断、姿勢を保つ小移動、更新画像からのVLA操作を接続し、果実回収まで実行するシステムを構築した。同じ初期状態のペア比較を行い、観察だけでなく持上げ保持とトレー収容を分けて評価した。

実測から得られた結論

既存の葉あり5条件では、再観察手順の追加時に収容成功数が2/5から4/5へ増えた。新規10配置では両方式4/10で、効果は配置に依存した。追加観察が、その後の操作全体を一律に改善する結果にはならなかった。

結果をどう解釈するか

今回比較したのは、視点移動を含む手順全体である。移動は視覚情報に加え、アーム姿勢、接近経路、VLA開始時刻、残り操作予算も変える。なし方式でも通常動作中に果実が見えるため、収容数の差を視覚情報だけの効果とは特定できない。

新規配置で持上げ保持が8/10から5/10へ低下したことは、観察後の状態からの操作に改善余地があることを示す。少数・局所配置での結果であり、未知作物や実農場での性能は本比較の対象外である。

農作業への応用に向けた次の課題

課題	次に行うこと
操作との整合	観察後の画像・姿勢を含む教師データを整え、把持から開放までの安定性を評価する。
効果の切り分け	姿勢や開始時刻を揃えた追加比較で、視覚情報と移動の寄与を分ける。
対象と環境の拡張	色規則を一般化し、果実・照明・葉の多様性、衝突、実機での扱いへ段階的に広げる。

参考文献・再現情報

背景の根拠と、結果・採用設定をたどるための情報。

[1] Hemming, J., Ruizendaal, J., Hofstee, J. W., & van Henten, E. J. (2014).
Fruit Detectability Analysis for Different Camera Positions in Sweet-Pepper. Sensors, 14(4), 6032-6044.
https://doi.org/10.3390/s140406032

[2] Kurtser, P., & Edan, Y. (2018).
Statistical models for fruit detectability: spatial and temporal analyses of sweet peppers. Biosystems Engineering, 171, 272-289.
https://doi.org/10.1016/j.biosystemseng.2018.04.017

[3] Magalhães, S. A., Moreira, A. P., Santos, F. N. D., & Dias, J. (2022).
Active Perception Fruit Harvesting Robots - A Systematic Review. Journal of Intelligent & Robotic Systems, 105, Article 14.
https://doi.org/10.1007/s10846-022-01595-3

[4] Hugging Face Vision Language Action Models Research.
HuggingFaceVLA/smolvla_libero. 採用ベースモデル。参照日：2026年10月31日。
https://huggingface.co/HuggingFaceVLA/smolvla_libero

使用した公開技術・アセット

LeRobot・SmolVLA：Apache-2.0 / LIBERO・robosuite：MIT / MuJoCo：Apache-2.0。リンゴの元形状・テクスチャはYCB Object and Model Set (CC BY 4.0) 。加工内容と通知はコード同梱のTHIRD_PARTY_NOTICES.mdを参照。

結果と採用設定の記録

項目	同梱コードからの参照・設定
既存比較	experiments/20261031_0925_reobservation/ main_comparison/results.csv
新規配置比較	experiments/20261031_1145_leaf_holdout/ holdout_comparison/results.csv
採用設定	C1250 / n_action_steps=10 / rgb_early_approach_v10
検証環境	Windows・Docker・RTX 4070 SUPER。Python 3.12、PyTorch 2.7.1、LeRobot 0.6.2、MuJoCo 3.8.1。

実行手順と重みの照合情報はREADME.mdを参照。新規環境での構築確認と、採用重み・テクスチャの公開取得方法の整備は、資料作成時点で残っている。

公開用コード・再現情報の更新

GitHub（現在Private・閲覧と取得には認証が必要）

https://github.com/tayamash0528/PhysicalAI_final_project

コード・配布物

READMEとRelease v1.0.0を参照。重みとアセットは別ZIP。

採用モデル：継続学習1,250ステップ時点／n_action_steps=10。

結果：results/initial_comparison.csv

results/relocated_apple_comparison.csv

前8ページの実験時パスとの対応：docs/path_mapping.md

結果と最終診断

最初の葉あり5条件は収容2/5→4/5。別の10配置は4/10→4/10。

移動ありで、葉を消しても失敗する位置と、成功に変わる位置があった。

原因分析用に選んだ3配置の診断。本比較とは別集計。

この診断だけで原因を1つに限定しない。

確認範囲と残作業

既存キャッシュを使った構築・実行確認と、今回の取得・SHA検証は別。

Public変更後の未認証取得、新規環境の全工程は未確認。

YouTube URLと正式提出名は確定後に反映する。

正式提出名はOmniCampusアカウント名の確認後に設定。提出は未実施。